



# **UNIVERSIDAD NACIONAL DE MISIONES**

**Facultad de Ciencias, Exactas, Químicas y Naturales**

***Matemática***

Tecnicatura Universitaria en Microbiología


*Dr. Jonathan M. Schuster*

# Unidad 4 – Estadística descriptiva.

Tipos de variables. Organización y presentación de datos. Tablas de frecuencia. Representaciones gráficas (gráficos de barras, grafico de puntos, histogramas, diagramas de cajas y bigotes y diagrama de dispersión). Medidas de tendencia central (media aritmética, mediana, media geométrica, moda, media recortada). Medidas de dispersión (rango, varianza, desvío estándar, coeficiente de variación). Percentiles y valores atípicos. Uso de software para el análisis de datos e interpretación de resultados experimentales en contextos de las ciencias biológicas.

**Lacourly, N. (2012). Introducción a la estadística: (ed.). Editorial ebooks Patagonia - J.C. Sáez Editor.**

**<https://elibro.net/es/lc/elibrournam/titulos/68439>**



# Medidas de dispersión

- Las **medidas de dispersión** indican cuánto varían los datos alrededor de un valor central.
- Mientras las medidas de tendencia central resumen “dónde se ubican” los datos, las medidas de dispersión resumen “qué tan separados” están entre sí.
- Dos conjuntos de datos pueden tener la misma media, pero diferente variabilidad.
- Por eso, en ciencias experimentales no alcanza con informar solo el promedio.

# ¿Por qué es importante medir la dispersión?

La dispersión permite evaluar la variabilidad de los resultados.

En microbiología, esto puede indicar:

- diferencias entre réplicas experimentales;
- estabilidad de un procedimiento;
- heterogeneidad entre muestras;
- presencia de valores atípicos;
- confiabilidad de una medición.

Una baja dispersión indica datos más homogéneos.

Una alta dispersión indica datos más variables.

# Datos de ejemplo

- Se mide el recuento bacteriano en 8 muestras de agua, expresado en UFC/mL.
- Los datos obtenidos son:  
18; 19; 20; 21; 21; 22; 23; 24

Usaremos estos datos para calcular:

- rango
- varianza
- desvío estándar
- coeficiente de variación

# Rango

- El **rango** mide la diferencia entre el valor máximo y el valor mínimo del conjunto de datos.

$$R = x_{max} - x_{min}$$

Donde:

$$x_{max} = \text{valor maximo}$$

$$x_{min} = \text{valor minimo}$$

- Es la medida de dispersión más simple.

# Cálculo del rango

- Datos:

18; 19; 20; 21; 21; 22; 23; 24

- Paso 1: identificar el valor mínimo.

$$x_{min} = 18$$

- Paso 2: identificar el valor máximo.

$$x_{max} = 24$$

- Paso 3: restar máximo menos mínimo.

$$R = 24 - 18$$

$$R = 6$$

- El rango es:

$$R = 6 \text{ UFC/mL}$$



# Rango: interpretación, ventajas y desventajas

- El rango indica la amplitud total de los datos.
- En el ejemplo, los valores van desde 18 hasta 24 UFC/mL.

## **Ventajas**

- Es muy fácil de calcular.
- Permite conocer rápidamente la amplitud de los datos.
- Usa las mismas unidades que la variable medida.

## **Desventajas**

- Solo considera dos valores: el mínimo y el máximo.
- Es muy sensible a valores atípicos.
- No informa cómo se distribuyen los datos entre el mínimo y el máximo.

# Varianza

- La **varianza** mide la dispersión promedio de los datos respecto de la media.
- Para una muestra, se calcula como:

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

- Donde:

$x_i$  = cada dato

$\bar{x}$  = media aritmetica

$n$  = cantidad de datos

- La varianza trabaja con desviaciones elevadas al cuadrado.

# Paso 1: calcular la media

- Datos:

18; 19; 20; 21; 21; 22; 23; 24

- Primero calculamos la media:

$$\bar{x} = \frac{18 + 19 + 20 + 21 + 21 + 22 + 23 + 24}{8}$$
$$\bar{x} = \frac{168}{8}$$
$$\bar{x} = 21$$

- La media del recuento bacteriano es:

$$\bar{x} = 21 \text{ UFC/mL}$$

## Paso 2: calcular las desviaciones respecto de la media

- A cada dato se le resta la media:

$$x_i - \bar{x}$$

Como:

$$\bar{x} = 21$$

obtenemos:

## Paso 2: calcular las desviaciones respecto de la media

| $Dato(x_i)$ | $(x_i - \bar{x})$ |
|-------------|-------------------|
| 18          | -3                |
| 19          | -2                |
| 20          | -1                |
| 21          | 0                 |
| 21          | 0                 |
| 22          | 1                 |
| 23          | 2                 |
| 24          | 3                 |

# Paso 3: elevar las desviaciones al cuadrado

- Paso 3: elevar las desviaciones al cuadrado

| $Dato(x_i)$ | $(x_i - \bar{x})$ | $((x_i - \bar{x})^2)$ |
|-------------|-------------------|-----------------------|
| 18          | -3                | 9                     |
| 19          | -2                | 4                     |
| 20          | -1                | 1                     |
| 21          | 0                 | 0                     |
| 21          | 0                 | 0                     |
| 22          | 1                 | 1                     |
| 23          | 2                 | 4                     |
| 24          | 3                 | 9                     |

- Luego se suman los cuadrados:

$$9 + 4 + 1 + 0 + 0 + 1 + 4 + 9 = 28$$

## Paso 4: calcular la varianza muestral

- La varianza muestral se calcula dividiendo por  $n - 1$ .

Como hay 8 datos:

$$n = 8$$
$$s^2 = \frac{28}{8 - 1}$$

$$s^2 = \frac{28}{7}$$
$$s^2 = 4$$

- La varianza muestral es:

$$s^2 = 4 \text{ (UFC/mL)}^2$$

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

# Varianza: ventajas y desventajas

## **Ventajas**

- Usa todos los datos.
- Mide la dispersión respecto de la media.
- Es importante para muchos métodos estadísticos posteriores.
- Penaliza más las desviaciones grandes.

## **Desventajas**

- Sus unidades quedan elevadas al cuadrado.
- Es menos intuitiva que el desvío estándar.
- Es sensible a valores extremos.
- No siempre es fácil de interpretar directamente.



# Desvío estándar

- El **desvío estándar** es la raíz cuadrada de la varianza.
- Para una muestra:

$$s = \sqrt{s^2}$$

- Indica cuánto se alejan, en promedio, los datos respecto de la media.
- A diferencia de la varianza, el desvío estándar se expresa en las mismas unidades que la variable medida.

# Cálculo del desvío estándar

En el ejemplo anterior, la varianza muestral fue:

$$s^2 = 4$$

Entonces:

$$s = \sqrt{4}$$

$$s = 2$$

El desvío estándar es:

$$s = 2 \text{ UFC/mL}$$

Esto significa que los datos se alejan aproximadamente 2 UFC/mL de la media.

# Desvío estándar: interpretación

La media fue:

$$\bar{x} = 21 \text{ UFC/mL}$$

El desvío estándar fue:

$$s = 2 \text{ UFC/mL}$$

Una forma simple de interpretarlo es:

$$21 \pm 2 \text{ UFC/mL}$$

Esto indica que la mayor parte de los valores se encuentra cerca de la media, con una variación típica de aproximadamente 2 UFC/mL.

# Desvío estándar: ventajas y desventajas

## **Ventajas**

- Usa todos los datos.
- Se expresa en las mismas unidades que la variable.
- Es una de las medidas de dispersión más utilizadas.
- Permite comparar la variabilidad dentro de un mismo tipo de medición.

## **Desventajas**

- Es sensible a valores extremos.
- Su interpretación puede ser difícil si la distribución es muy asimétrica.
- Debe acompañarse de la media y del contexto experimental.

# Coeficiente de variación

El **coeficiente de variación** mide la dispersión relativa de los datos respecto de la media.

Se expresa como porcentaje.

$$CV = \frac{s}{\bar{x}} \times 100$$

Donde:

$$s = \text{desvio estandar}$$

$$\bar{x} = \text{media aritmetica}$$

El coeficiente de variación permite comparar la variabilidad entre variables con diferentes unidades o diferentes escalas.

# Cálculo del coeficiente de variación

- En el ejemplo:

$$\bar{x} = 21 \text{ UFC/mL}$$

$$s = 2 \text{ UFC/mL}$$

- Aplicamos la fórmula:

$$CV = \frac{2}{21} \times 100$$

$$CV = 9,52\%$$

- El coeficiente de variación es:

$$CV = 9,52\%$$

# Interpretación del coeficiente de variación

- El coeficiente de variación indica qué tan grande es el desvío estándar en relación con la media.

- En este caso:

$$CV = 9,52\%$$

- Esto significa que la variabilidad relativa de los datos es cercana al 10 % de la media.

Un CV bajo indica resultados más homogéneos.

Un CV alto indica resultados más variables.

# Coeficiente de variación: ventajas y desventajas

## **Ventajas**

- Permite comparar variabilidad entre diferentes grupos.
- No depende directamente de la unidad de medida.
- Es útil para evaluar reproducibilidad experimental.
- Se interpreta como porcentaje.

## **Desventajas**

- No debe usarse si la media es cero o muy cercana a cero.
- Puede ser engañoso con datos que tienen valores negativos.
- Es sensible a valores extremos.
- Debe interpretarse junto con la media y el desvío estándar.



# Percentiles

- Los **percentiles** dividen un conjunto ordenado de datos en 100 partes.
- Un percentil indica el valor por debajo del cual se encuentra cierto porcentaje de observaciones.

Por ejemplo:

$$P_{25}$$

indica el valor por debajo del cual se encuentra aproximadamente el 25 % de los datos.

$$P_{50}$$

corresponde a la mediana.

$$P_{75}$$

indica el valor por debajo del cual se encuentra aproximadamente el 75 % de los datos.

# Percentiles en microbiología: recuento bacteriano

- En un laboratorio se analiza el recuento de bacterias heterótrofas en muestras de agua, expresado en UFC/mL.
- Datos ordenados:  
12; 14; 15; 16; 18; 19; 20; 21; 22; 24; 25; 26; 28; 30; 35; 40
- El percentil 25,  $P_{25}$ , indica el valor por debajo del cual se encuentra aproximadamente el 25 % de las muestras.
- Como hay 16 datos:

$$25\% \text{ de } 16 = 4$$

- Aproximadamente, el 25 % de las muestras tiene valores hasta la posición 4.

$$P_{25} \approx 16 \text{ UFC/mL}$$

# Percentil 50: la mediana

- El percentil 50,  $P_{50}$ , corresponde a la **mediana**.
- Indica el valor que divide los datos en dos partes:
- 50 % de las observaciones queda por debajo;
- 50 % queda por encima.
- Datos ordenados:  
12; 14; 15; 16; 18; 19; 20; 21; 22; 24; 25; 26; 28; 30; 35; 40
- Como hay 16 datos, la mediana se calcula promediando los valores de las posiciones 8 y 9:

$$P_{50} = \frac{21 + 22}{2}$$
$$P_{50} = 21,5 \text{ UFC/mL}$$

# Percentiles más usados

- Los percentiles son útiles para describir la posición de un dato dentro de una distribución.

| Percentil  | Nombre frecuente         | Interpretación                     |
|------------|--------------------------|------------------------------------|
| $(P_{25})$ | Primer cuartil ( $Q_1$ ) | 25 % de los datos queda por debajo |
| $(P_{50})$ | Mediana ( $Q_2$ )        | 50 % de los datos queda por debajo |
| $(P_{75})$ | Tercer cuartil ( $Q_3$ ) | 75 % de los datos queda por debajo |

# Rango intercuartílico

- El **rango intercuartílico** mide la dispersión del 50 % central de los datos.
- Se calcula como:

$$RIQ = Q_3 - Q_1$$

En el ejemplo:

$$Q_1 = 19,5$$

$$Q_3 = 22,5$$

- Entonces:

$$RIQ = 22,5 - 19,5$$

$$RIQ = 3$$

- El 50 % central de los datos se encuentra en un rango de 3 UFC/mL.

# Valores atípicos

- Un **valor atípico** es un dato que se encuentra muy alejado del resto de las observaciones.
- Puede deberse a:
  - error de medición;
  - error de carga de datos;
  - contaminación de una muestra;
  - variabilidad real del fenómeno;
  - una condición experimental diferente.

Un valor atípico no debe eliminarse automáticamente.  
Primero debe analizarse su origen.

# Criterio del rango intercuartílico

- Una forma frecuente de detectar posibles valores atípicos usa el rango intercuartílico.
- Primero se calculan:  $Q_1$ ,  $Q_3$ ,  $RIQ = Q_3 - Q_1$
- Luego se definen los límites:  
$$\text{Limite inferior} = Q_1 - 1,5 \times RIQ$$
$$\text{Limite superior} = Q_3 + 1,5 \times RIQ$$
- Los datos fuera de esos límites se consideran posibles valores atípicos.

# Ejemplo de detección de atípicos

- Datos:

18; 19; 20; 21; 21; 22; 23; 24

- Ya calculamos:

$$Q_1 = 19,5$$

$$Q_3 = 22,5$$

$$RIQ = 3$$

- Límite inferior:

$$19,5 - 1,5 \times 3 = 15$$

- Límite superior:

$$22,5 + 1,5 \times 3 = 27$$

- Los datos deben estar entre 15 y 27 para no ser considerados atípicos.
- En este conjunto no hay valores atípicos.



# Ejemplo con un valor atípico

- Supongamos ahora que se obtiene el siguiente conjunto:

18; 19; 20; 21; 21; 22; 23; 24; 60

- El valor:

60

- está muy alejado del resto de los datos.
- Puede corresponder a una muestra contaminada, un error de medición o una situación real que requiere análisis.
- Antes de eliminarlo, se debe revisar el procedimiento experimental.

# Criterio de $\pm 3$ desvíos estándar para valores atípicos

- Un criterio simple para detectar posibles valores atípicos consiste en comparar cada dato con la media y el desvío estándar.
- Primero se calculan:

$$\bar{x} = \textit{media}$$

$$s = \textit{desvio estandar}$$

- Luego se construye el intervalo:
- $\bar{x} - 3s \leq x \leq \bar{x} + 3s$
- Los valores que quedan fuera de ese intervalo se consideran **posibles valores atípicos**.

# Criterio de $\pm 3$ desvíos estándar para valores atípicos

- Este criterio es más adecuado cuando los datos tienen una distribución aproximadamente simétrica.
- Si los datos son muy asimétricos, puede ser más conveniente usar criterios basados en percentiles o en el rango intercuartílico.

# Efecto de un valor atípico

- Los valores atípicos pueden afectar fuertemente algunas medidas estadísticas.
- Especialmente:
- media aritmética;
- rango;
- varianza;
- desvío estándar;
- coeficiente de variación.

En cambio, afectan menos a:

- mediana;
- cuartiles;
- rango intercuartílico;
- media recortada.

Por eso, cuando hay atípicos, conviene analizar más de una medida.

# Resumen general

| Medida                   | Qué informa                                | Sensible a atípicos |
|--------------------------|--------------------------------------------|---------------------|
| Rango                    | Amplitud total de los datos                | Sí                  |
| Varianza                 | Dispersión cuadrática respecto de la media | Sí                  |
| Desvío estándar          | Dispersión típica respecto de la media     | Sí                  |
| Coeficiente de variación | Dispersión relativa porcentual             | Sí                  |
| Percentiles              | Posición dentro de los datos ordenados     | Poco                |
| RIQ                      | Dispersión del 50 % central                | Poco                |

# Dispersión y tendencia central

- Las medidas de dispersión complementan a las medidas de tendencia central.
- Un promedio sin una medida de dispersión puede ser insuficiente o incluso engañoso.
- En un análisis descriptivo completo conviene informar, según el caso:

$$\bar{x} \pm s$$

o bien:

mediana,  $Q_1$ ,  $Q_3$

- La elección depende de la forma de la distribución, la presencia de valores atípicos y el objetivo del análisis.

# ¿Por qué estudiar medidas de dispersión?

- En un laboratorio se desea cuantificar un metabolito producido por un hongo.
- Para validar el análisis, se dispone de un **patrón de concentración conocida**:

*100 mg/L*

- Se comparan dos técnicas analíticas:
- **Técnica A:** resultados muy variables.  
**Técnica B:** resultados más consistentes.

La pregunta es:

¿Cuál técnica permite medir mejor el metabolito?

# Dos técnicas, mismo objetivo

- Se mide el mismo patrón de metabolito 10 veces con cada técnica. (mg/L)

| Repetición | Técnica A | Técnica B |
|------------|-----------|-----------|
| 1          | 84        | 98        |
| 2          | 116       | 101       |
| 3          | 91        | 99        |
| 4          | 127       | 102       |
| 5          | 78        | 100       |
| 6          | 108       | 97        |
| 7          | 95        | 103       |
| 8          | 132       | 99        |
| 9          | 88        | 101       |
| 10         | 121       | 100       |



# ¿Qué muestran los promedios?

- Calculamos la media aritmética de cada técnica:

$$\bar{x}_A = 104,0 \text{ mg/L}$$

$$\bar{x}_B = 100,0 \text{ mg/L}$$

- Ambas técnicas tienen promedios cercanos al valor real del patrón:  
 $100 \text{ mg/L}$
- Pero esto no significa que ambas técnicas sean igualmente buenas.
- Para comparar correctamente, también necesitamos analizar la **dispersión**.

# La media no alcanza

- La Técnica A tiene valores muy alejados entre sí:  
78, 84, 88, ..., 127, 132
- La Técnica B tiene valores mucho más cercanos entre sí:  
97, 98, 99, ..., 102, 103
- Aunque las medias sean parecidas, la variabilidad es muy diferente.
- Una técnica analítica útil no solo debe ser cercana al valor real, también debe ser **reproducible**.

# Comparación de la dispersión

| Medida                   | Técnica A  | Técnica B  |
|--------------------------|------------|------------|
| Media                    | 104,0 mg/L | 100,0 mg/L |
| Mínimo                   | 78 mg/L    | 97 mg/L    |
| Máximo                   | 132 mg/L   | 103 mg/L   |
| Rango                    | 54 mg/L    | 6 mg/L     |
| Desvío estándar          | 19,6 mg/L  | 1,8 mg/L   |
| Coeficiente de variación | 18,8 %     | 1,8 %      |

- La Técnica B presenta mucha menor dispersión.

# Interpretación experimental

- La Técnica A tiene un promedio cercano al valor esperado, pero sus resultados son muy variables.
- Esto significa que una medición individual puede alejarse bastante del valor real.
- La Técnica B presenta resultados más concentrados alrededor del patrón.
- Por lo tanto, la Técnica B es más precisa y reproducible.
- En un laboratorio, una técnica con menor dispersión suele ser preferible para cuantificar metabolitos, siempre que además sea exacta y esté correctamente calibrada.

# Precisión y exactitud

- En mediciones experimentales conviene distinguir dos ideas:
- **Exactitud:** cercanía al valor verdadero o aceptado.
- **Precisión:** cercanía entre mediciones repetidas.
- Una técnica puede tener una media cercana al valor real, pero ser poco precisa si sus mediciones son muy variables.
- Por eso, para evaluar una técnica no alcanza con mirar solo la media.
- También debemos analizar:  
rango, varianza, desvío estándar y coeficiente de variación

# Recapitulando

- Las medidas de tendencia central indican el valor típico de los datos.
- Las medidas de dispersión indican cuánto varían esos datos.
- En este ejemplo, ambas técnicas parecen aceptables si solo miramos el promedio.
- Pero al analizar la dispersión, queda claro que la Técnica B es mucho más consistente.
- La dispersión permite tomar mejores decisiones experimentales.

# Diagrama de cajas y bigotes

- El **diagrama de cajas y bigotes** es una representación gráfica que resume la distribución de un conjunto de datos.

Permite visualizar rápidamente:

- el valor central de los datos;
- la dispersión;
- la simetría o asimetría;
- la presencia de posibles valores atípicos.

Es especialmente útil para comparar varios grupos o tratamientos experimentales.

# ¿Qué muestra un diagrama de cajas?

- Un diagrama de cajas y bigotes se construye a partir de cinco valores principales:

mínimo,  $Q_1$ , mediana,  $Q_3$ , máximo

Donde:

- $Q_1 = \text{primer cuartil}$
- $Q_2 = \text{mediana}$
- $Q_3 = \text{tercer cuartil}$
- La caja contiene el 50 % central de los datos.
- Los bigotes muestran la extensión de los datos sin considerar los posibles valores atípicos.



# Interpretación de la caja

- La parte central del gráfico es la **caja**.
- El borde inferior de la caja representa:

$$Q_1$$


- El borde superior representa:

$$Q_3$$

- La línea dentro de la caja representa la **mediana**.
- La amplitud de la caja se llama **rango intercuartílico**:

$$RIQ = Q_3 - Q_1$$

- Cuanto más grande es la caja, mayor es la dispersión del 50 % central de los datos.



# Ejemplo experimental

- Se desea cuantificar un metabolito producido por un hongo.
- Para ello se comparan dos técnicas analíticas.
- Cada técnica se aplica 10 veces sobre muestras similares.
- Los resultados se expresan en:  
 $\text{mg/L}$
- El objetivo es evaluar cuál técnica produce resultados más consistentes.


# Datos experimentales

| Repetición | Técnica A | Técnica B |
|------------|-----------|-----------|
| 1          | 78        | 97        |
| 2          | 84        | 98        |
| 3          | 88        | 99        |
| 4          | 91        | 99        |
| 5          | 95        | 100       |
| 6          | 108       | 100       |
| 7          | 116       | 101       |
| 8          | 121       | 101       |
| 9          | 127       | 102       |
| 10         | 132       | 103       |

# Resumen

| Medida          | Técnica A | Técnica B |
|-----------------|-----------|-----------|
| Mínimo          | 78        | 97        |
| (Q_1)           | 88,75     | 99,00     |
| Mediana         | 101,50    | 100,00    |
| (Q_3)           | 119,75    | 101,00    |
| Máximo          | 132       | 103       |
| RIQ             | 31,00     | 2,00      |
| Desvío estándar | 19,28     | 1,83      |

Comparación de dos técnicas analíticas



- La Técnica A tiene resultados muy variables.
- Aunque algunos valores están cerca de 100 mg/L, otros se alejan mucho.
- La Técnica B muestra resultados más agrupados alrededor de 100 mg/L.
- Por lo tanto, la Técnica B parece más precisa para cuantificar el metabolito.
- En un laboratorio, una técnica con menor dispersión suele ser preferible cuando se busca reproducibilidad.

# Boxplot con valores atípicos

- Supongamos ahora una tercera técnica con los siguientes resultados:  
82; 85; 86; 88; 90; 91; 93; 95; 130; 145
- Los valores 130 y 145 mg/L están muy alejados del grupo principal.
- En el boxplot aparecen como puntos separados.
- Esto sugiere posibles valores atípicos.



Diagrama de caja con posibles valores atípicos

